

TALLER 1 - CORTE 3

Reinforcement Learning - Diseno de MDP

Valuacion Inmobiliaria Automatizada - Ames Housing 2006-2024

Campo	Detalle
Integrantes	Julian Esteban Rincon R. - Valeria Larea - Nicolas Garzon - Juan Nino
Programa	Ingenieria de Sistemas - Universidad Sergio Arboleda
Curso	Machine Learning - Corte 3
Dataset	Ames Housing 2006-2024 (20,203 registros, 81 features)
Modelo Base	K-Means (k=6) + XGBoost - R2=0.9606, MAE=6,254
Fecha	Abril 2026

Introduccion: Por que un MDP para valuacion inmobiliaria?

El contexto del problema. La valuacion inmobiliaria tradicional depende de tasadores humanos subjetivos, lentos y costosos. Nuestro analisis previo demostro que un modelo hibrido K-Means + XGBoost logra $R^2=0.9606$ con $MAE=6,254$ sobre el dataset de Ames, Iowa (2006-2024). Sin embargo, una prediccion de precio aislada no es suficiente: el agente debe tomar decisiones secuenciales como aprobar la tasacion, solicitar revision humana o rechazar por datos insuficientes.

Por que un MDP? Un Proceso de Decision de Markov permite modelar exactamente ese tipo de decision secuencial. El agente observa el estado actual del inmueble (su cluster de mercado via K-Means), toma una accion (APROBAR/REVISAR/RECHAZAR) y recibe una recompensa segun el resultado economico. Los modelos supervisado y no supervisado entrenados previamente se integran directamente como componentes del MDP.

CONEXION CLAVE: K-Means define los ESTADOS del MDP. XGBoost define la funcion de TRANSICION. Value Iteration extrae la POLITICA optima. Tres paradigmas del curso integrados en un agente.

Pregunta 1: Objetivo y Agente

Cual es el objetivo unico a optimizar?

Objetivo: Maximizar el valor economico esperado de las decisiones de tasacion inmobiliaria a largo plazo, minimizando el error de valuacion y los costos operativos asociados a revisiones innecesarias.

$$V^*(s) = \max_{\pi} E[\sum_{t=0}^{\infty} \gamma^t R(st, at) \mid s_0 = s] \text{ donde } \gamma = 0.95$$

Quien es el agente?

El agente es el Sistema Autonomo de Valuacion Inmobiliaria (SAVI). Funciona como un tasador algoritmico que, dado el perfil de una propiedad (su cluster de mercado), decide si la valuacion generada por el XGBoost es suficientemente confiable para aprobarla, si requiere revision humana, o si debe ser rechazada por datos insuficientes.

Stakeholder	Rol	Interaccion con el Agente
Propietario	Beneficiario primario	Recibe la valuacion final
Banco / Financiera	Usuario institucional	Usa la decision para aprobar credito
Tasador humano	Supervisor	Interviene solo cuando SAVI pide Revision
SAVI (el agente)	Decisor autonomo	Opera el MDP en tiempo real 24/7

Pregunta 2: Las Acciones (A)

$A = \{ \text{APROBAR}, \text{REVISAR}, \text{RECHAZAR} \}$

Accion	Descripcion	Costo Operativo	Cuando es valida
APROBAR	Emitir la valuacion del XGBoost como precio oficial	/bin/sh	Cluster bien definido, error esperado bajo
REVISAR	Enviar a tasador humano para validacion manual	50-00	Cluster limitrofe o features atipicos
RECHAZAR	Devolver al solicitante pidiendo mas documentacion	0	Datos incompletos, fuera del dominio del modelo

Por que 3 acciones y no mas? La maldicion de la dimensionalidad aplica tambien al espacio de acciones: mas acciones implica mas pares (s,a) que estimar y mas datos necesarios. Tres acciones representan los tres escenarios economicamente distintos del proceso de tasacion y son suficientes para capturar toda la variabilidad real del problema.

Pregunta 3: Los Estados (S)

3.1 Conexion con el analisis no supervisado

Los estados del MDP **son directamente los clusters del K-Means** entrenado sobre el dataset de Ames. Con $k=6$ optimo (silhouette aprox. 0.27), cada cluster representa un perfil de mercado homogeneo:

Estado (Cluster)	Perfil de Mercado	Precio Medio	% Dataset
S0 - Atipico pequeno	Props. con features inusuales, escasos datos	40K	3.8%
S1 - Estandar bajo	Vivienda familiar basica, calidad media-baja (4-5)	57K*	29.5%
S2 - Calidad alta	Alta calidad, medianas, renovadas (7+)	36K	3.1%
S3 - Premium raro	Ultra-premium, solo 7 propiedades historicas	88K	0.03%
S4 - Compacto medio	Propiedades compactas, buen vecindario	95K	31.1%
S5 - Estandar amplio	Casas amplias, mercado activo	50K	32.5%

3.2 Solucion a la maldicion de la dimensionalidad

El problema original: el dataset tiene 81 features originales que se expanden a 265 features post-encoding. Usar todas directamente para definir estados hace imposible la estimacion de $P(s|s,a)$.

La solucion K-Means: En lugar de 265 dimensiones, el estado se comprime a 1 numero entero (0-5) correspondiente al cluster asignado. Esta compresion es estadisticamente rigurosa porque K-Means minimiza la suma de distancias al centroide, garantizando que propiedades en el mismo cluster se comportan economicamente igual.

JUSTIFICACION: K-Means minimiza $\sum ||x_i - m_k||^2$. Propiedades en el mismo cluster tienen features similares, comportamientos de precio predecibles y transiciones de estado estimables. Dimension efectiva: $265 \rightarrow 6$.

Pregunta 4: La Recompensa (R)

Accion	Resultado	Recompensa $R(s,a)$	Justificacion economica
APROBAR	Error < 10%	+00	Valuacion correcta, valor agregado confirmado
APROBAR	Error 10-25%	-00	Correccion necesaria, costo reputacional estimado
APROBAR	Error > 25%	-,000	Diferencia > 0K en prop. media, litigio posible
REVISAR	Tasador confirma	-50	Costo de revision asumido como precio del control
REVISAR	Tasador corrige	-0	Revision valida: costo parcial compensado por valor
RECHAZAR	Datos insuficientes	+0	Accion correcta: evita valuar con info incompleta
RECHAZAR	Datos suficientes	-00	Rechazo innecesario: perdida de oportunidad

El dilema matematico - Ecuacion de Bellman aplicada

Por que el agente aprende a REVISAR en estados de alta incertidumbre? No por programacion directa, sino por la matematica de la ecuacion de Bellman:

$Q(S4, APROBAR) = 0.70 \times (+200) + 0.20 \times (-500) + 0.10 \times (-2000) = -160$
 $Q(S4, REVISAR) = -150$ con certeza $\rightarrow$ El agente aprende: $-150 > -160 \rightarrow$ REVISAR es racional en estados de incertidumbre

Pregunta 5: La Transicion $P(s|s, a)$

Construccion de la tabla de transicion

Metodo utilizado: Para cada estado s se usa $\text{shift}(-1)$ sobre la columna state agrupada para obtener el estado siguiente s . La probabilidad $P(s|s) = \text{count}(s \rightarrow s) / \text{count}(s)$ sobre los 20,203 registros historicos del dataset de Ames.

Estado actual	$\rightarrow S0$	$\rightarrow S1$	$\rightarrow S2$	$\rightarrow S3$	$\rightarrow S4$	$\rightarrow S5$
S0	0.514	0.001	0.443	0.005	0.004	0.033
S1	0.000	0.879	0.000	0.000	0.015	0.106
S2	0.534	0.005	0.411	0.005	0.000	0.045
S3	1.000	0.000	0.000	0.000	0.000	0.000
S4	0.000	0.013	0.000	0.000	0.960	0.027
S5	0.005	0.097	0.004	0.000	0.025	0.870

Validacion con XGBoost (Opcion B avanzada): El modelo XGBoost entrenado puede predecir el cluster futuro de una propiedad con features modificados, validando que las probabilidades estimadas por conteo historico son coherentes con el comportamiento real del mercado.

Estados pegajosos: $S1 \rightarrow S1$: 0.879, $S4 \rightarrow S4$: 0.960, $S5 \rightarrow S5$: 0.870. Una propiedad en su segmento raramente salta a otro cluster. Esto es economicamente realista: el mercado no se transforma radicalmente de un año a otro.

Parte 2: Implementacion del MDP

Arquitectura del sistema

Paso	Componente	Implementacion
1	Limpieza de datos	Pipeline de imputacion: None para ausencias categoricas, mediana por vecindario para LotFrontage
2	Definicion de estados	KMeans(k=6).predict(X_scaled) → columna state con valores 0-5
3a	Funcion de recompensa	$R = f(\text{error_pct}, \text{accion})$ segun tabla de costos economicos reales
3b	Tabla de transicion	shift(-1) sobre la columna state → tabla $P[s][s]$ calculada con conteo historico
4	Value Iteration	value_iteration(P, R, gamma=0.95, theta=0.0001) → $V^*(s)$ por estado
5	Politica optima	$\pi^*(s) = \operatorname{argmax}_a Q(s,a)$ para cada estado → politica final del agente

Modificaciones clave respecto al codigo base

- Paso 2: Se elimino pd.qcut y se reemplazo por KMeans(k=6).fit_predict(X_scaled). Justificacion: el clustering semantico agrupa propiedades por similitud economica real, no por cuantiles arbitrarios de una sola variable.
- Paso 3a: Se reescribio la logica de recompensa con $f(\text{error_pct}, \text{accion})$ basada en costos financieros reales del proceso de tasacion bancaria.
- Paso 3b: Se mantiene la logica shift(-1) del codigo base, adaptada para que los estados sean los clusters K-Means en lugar de categorias de precio discretizadas.
- Pasos 4 y 5: El algoritmo de Value Iteration y la extraccion de politica se mantienen identicos al codigo base; los pasos anteriores garantizan que operen correctamente.

Parte 3: Política Optima y Reglas de Oro

Resultado de la Value Iteration

Estado	Perfil	V*(s)	Política pi*(s)	R(APROBAR)	R(REVISAR)	R(RECHAZAR)
S0 - Atípico	3.8%	-1770.9	REVISAR	-219.6	-108.0	-161.5
S1 - Est. bajo	29.5%	-1211.7	APROBAR	-62.1	-120.3	-182.4
S2 - Cal. alta	3.1%	-1774.3	REVISAR	-129.6	-114.8	-179.2
S3 - Premium	0.03%	-1632.3	RECHAZAR	-2000.0	-50.0	+50.0
S4 - Compacto	31.1%	-613.1	APROBAR	-5.8	-127.4	-185.3
S5 - Amplio	32.5%	-1278.2	APROBAR	-81.8	-119.5	-180.9

Las 3 Reglas de Oro

Regla 1 - S3 siempre RECHAZA: la regla mas contraintuitiva

Observacion: El agente RECHAZA en S3 aunque parece rendirse. Solo 7 propiedades historicas (0.03% del dataset).

Explicacion RL: $R(\text{APROBAR}) = -2,000$ vs $R(\text{RECHAZAR}) = +50$. El agente descubrio por si solo que pedir mas documentacion (+0) y esperar una nueva tasacion con datos completos produce mayor valor futuro descontado que intentar valuar con informacion insuficiente (-,000). Esta regla emerge de la ecuacion de Bellman, no fue programada.

Regla 2 - El mercado mayoritario siempre APRUEBA

Observacion: S1, S4 y S5 (93.1% del dataset) siempre aprueban sin vacilar.

Explicacion RL: En estos clusters el XGBoost fue entrenado con la mayor parte de los datos. $R(\text{APROBAR})$ es solo - a -2, muy inferior al costo de revision (-20 a -50). El agente aprende que en el segmento mas entrenado, la automatizacion maximiza el valor economico total del portafolio.

Regla 3 - La incertidumbre activa la revision en S0 y S2

Observacion: S0 y S2 siempre REVISAN aunque podrian APROBAR.

Explicacion RL: S0 tiene alta tasa de datos atipicos ($R(\text{APROBAR})=-219.6$ vs $R(\text{REVISAR})=-108.0$). S2 agrupa propiedades de alta calidad con mayor heterogeneidad interna ($R(\text{APROBAR})=-129.6$ vs $R(\text{REVISAR})=-114.8$). En ambos casos el costo esperado de APROBAR supera al de REVISAR. El agente aprende a proteger estos segmentos.

RESULTADO FINAL: SAVI opera con APROBAR en el 93.1% de casos (S1+S4+S5), REVISAR en el 6.9% (S0+S2) y RECHAZAR solo para el 0.03% critico (S3). Automatizacion maxima con control donde realmente importa.

Conclusiones

- INTEGRACION: K-Means (no supervisado) genera los estados. XGBoost (supervisado) informa las transiciones. Value Iteration extrae la política. Tres paradigmas del curso integrados en un unico agente autonomo.
- EMERGENCIA: Las 3 reglas de oro no fueron programadas manualmente. Emergieron de 259 iteraciones de Value Iteration con $\gamma=0.95$ y $\theta=0.0001$ sobre recompensas economicas reales.
- ESCALA: El framework MDP es extensible con Q-Learning online, embeddings de propiedades en lugar de K-Means, o series de tiempo de precios por vecindario para el paso de transicion.